

TEXT PROCESSING

Data : Wongnai Reviews



STEP 0

Install and import dependencies

Import pythainlp (คือ Library แพคเกจของภาษา Python ใช้สำหรับ ประมวลผลข้อความ และการวิเคราะห์ทางภาษา คล้ายกับ NLTK แต่ใช้กับ ภาษาไทยโดยเฉพาะ มีฟังก์ชันการทำงานที่หลากหลาย)



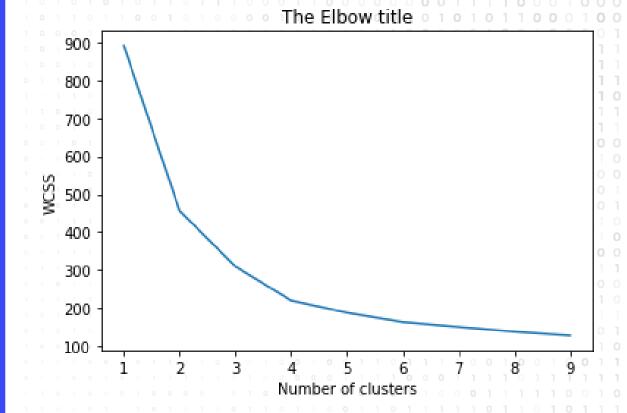
Document embedding and dimension reduction

ใช้ Model ของ Universal Sentence Encoder (USE) ในการสร้าง Vector representation หรือ Embeddings เพื่อนำไปใช้ในหาความเหมือนของ ประโยคหรือนำไปใช้ต่อในโมเดลอื่น ๆ



Document clustering using K-means

เพื่อจัดกลุ่มว่า Document ไหนอยู่กลุ่มเดียวกัน โดยใช้ K-means Clustering (เป็นการใช้ค่ายูคลิเดียนในการวัดระยะห่าง) โดยเมื่อดูกราฟ Elbow พบว่าจะ ได้ **K =3** ในสไลด์กัดไป



K-based on the elbow plot (K=3)

Step 2 - document clustering using K-Means



STEP 3

Document clustering using Agglomorative Clustering

with cosine similarity

เพื่อจัดกลุ่มว่า Document ไหนอยู่กลุ่มเดียวกันโดยใช้ Agglomorative Clustering เป็น Hierarchical Method (หาค่า cosine)







CAFÉ COFFEE

เน้นรีวิวร้านคาเฟ่ที่เป็น ร้านกาแฟ มีการพูดถึง บรรยากาศของร้าน รสชาติ และราคา



สายแซ่บ SOCIETY

เน้นริวิ<mark>วร้านอาหาร มัก</mark> กินข้าวกับกลุ่มเพื่อน ส่วนใหญ่เป็นร้านส้มตำ ชอบทานอาหารรสจัด



รักใครก็ไม่เท่า "ชานมไข่มุก"

เน้นรีวิวเครื่องดื่ม ประเภทชานมไข่มุก ชานมไต้หวัน ชาเขียว เป็นหลัก